

베이지스 모델

I. 나이브 베이지스 모델

II. 움퍼스 월드 다시 보기

I. 나이브 베이즈 모델

전체 결합 확률 분포

$$P(\underbrace{Cause, Effect_1, \dots, Effect_n}_{\text{주어진 원인에 대해 조건부 독립}}) = P(Cause) \prod_i P(Effect_i | Cause)$$

주어진 원인에 대해
조건부 독립

- ◆ 일반적으로 "효과" 변수들($Effect_1, \dots, Effect_n$)이 엄격하게 독립적이지 않은 경우에도 잘 작동

추론

- 관측된 효과 : $E = e$
- 관측되지 않은 효과: $Y = y$

$$\begin{aligned} P(Cause | e) &= \alpha \sum_y P(Cause, e, y) && \text{효과의 조건부 독립} \\ & && \equiv P(e | Cause) \\ &= \alpha \sum_y P(Cause) P(y | Cause) \left(\prod_j P(e_j | Cause) \right) \\ &= \alpha P(Cause) \left(\prod_j P(e_j | Cause) \right) \underbrace{\sum_y P(y | Cause)}_{= 1} \\ &= \alpha P(Cause) \left(\prod_j P(e_j | Cause) \right) \end{aligned}$$

효과가 조건부 독립이 아닐 때:

$$P(Cause | e) = \alpha P(Cause) P(e | Cause)$$

(cont'd)

$$P(Cause | e) = \alpha P(Cause) \left(\prod_j P(e_j | Cause) \right)$$

관측된 효과를 바탕으로 원인의 확률 분포를 계산:

- 가능한 모든 원인을 취함
 - 각 원인 별로 관측된 모든 결과에 대한 조건부 확률의 곱과 사전 확률을 곱해 줌
 - 결과를 정규화
-
- ◆ 관측된 결과의 개수에 대해서만 *선형으로 비례하여 시간 소요*
 - ◆ 관측되지 않은 효과의 수는 얼마나 크든 상관 없음(예. 의학)

텍스트 분류

문제: 주어진 텍스트가 미리 정의된 일련의 클래스 또는 범주 중 어디에 속하는지 결정

“원인” → (신문의 섹션) *범주 카테고리*, e.g.,

{news, sports, business, weather, entertainment }

“결과” → $HasWord_i$: i^{th} 번째 키워드의 존재 또는 부재

예시 문장

1. 월요일 주식 상승. 주요 지수가 1% 상승하여 1분기 실적 시즌에 대한 낙관론 지속
2. 월요일 동부 해안 대부분에 계속된 폭우로 뉴욕시 및 기타 지역에서 홍수 경보 발령

각 문장을 범주에 맞게 분류

분류 (cont'd)

- 사전 확률: $P(\text{Category})$
- 조건부 확률: $P(\text{HasWord}_i \mid \text{Category})$

♣ $P(\text{Category} = c) \approx$ 이전에 본 모든 문서 중 범주 c 에 속하는 문서의 비율

$P(\text{Category} = \text{weather}) = 0.09$ // 9%의 기사가 날씨에 관한 것임

♣ $P(\text{HasWord}_i \mid \text{Category}) \approx$ 각 범주에 속하는 문서 중 단어 i 를 포함하는 문서의 비율

$P(\text{HasWord}_6 = \text{true} \mid \text{Category} = \text{business}) \approx 0.37$

// 비즈니스 분야의 기사 중 6번 단어인 “stocks”을
// 포함하는 기사의 비율은 37%

분류 알고리즘

- ◆ 문서 내용에 어떤 키워드(즉, 효과)가 나타나는지 확인
- ◆ 각 카테고리(즉, 원인)에 대한 사후 확률 분포 계산

$$P(Category | HasWords) = \alpha P(Category) \left(\prod_j P(HasWord_j | Category) \right)$$

e.g., $HasWords = HasWord_1 = true \wedge HasWord_2 = false \wedge \dots$

각 키워드 별 출현 여부

나이브 베이즈 모델의 다른 응용 사례

- ◆ 언어 판별(텍스트가 작성에 사용된 언어 감지)
- ◆ 스팸 필터링(스팸 이메일 식별)
- ◆ 감성 분석(소셜 미디어에서 고객의 긍/부정 감정 식별)
- ◆ 실시간 예측(고속 상황 예측)
- ◆ 추천 시스템(감지되지 않은 정보 필터링 및 사용자가 대상 자원을 좋아하는지 예측)

나이브 베이즈 모델이 사용되지 않는 분야

- ♠ 의료 진단 분야(더 복잡한 고급 모델 필요)

II. 움퍼스 월드 다시 보기

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2 B OK	2,2	3,2	4,2
1,1 OK	2,1 B OK	3,1	4,1

이 3개 방에 함정이
있을 수 있음

♠ 논리 추론으로는 어떤 방이 가장 안전할 가능성이 높은지 결론을 내릴 수 없음

♠ 논리적 에이전트가 취할 수 있는 방안은 3개 방 중 하나를 무작위로 선택하는 것

♦ 각 방 [1,3], [2,2], [3,1]에 구덩이가 있을 확률을 계산

- 함정은 모든 이웃하는 방에 바람을 일으킴
- [1, 1] 이외의 방에 구덩이가 있을 확률은 0.2

♦ 계산에 필요한 랜덤 변수 지정

- $P_{i,j}$: 방 [i, j]에 구덩이가 있는 경우 true
- $B_{i,j}$: 방 [i, j]에 바람이 부는 경우 true – 이미 방문한 방을 대상으로 함, 즉 [1,1], [1,2], [2,1].

전체 결합 확률 분포

$$P(P_{1,1}, \dots, P_{4,4}, B_{1,1}, B_{1,2}, B_{2,1}) =$$

// $P_{1,1} \equiv \text{false}$

$$P(B_{1,1}, B_{1,2}, B_{2,1} \mid P_{1,1}, \dots, P_{4,4}) P(P_{1,1}, \dots, P_{4,4})$$

주어진 함정 구성에 대한 분포의 값은
방 [1,1], [1,2], [2,1] 중 바람이 부는
방이 함정 방과 인접한 경우 1이고,
그렇지 않으면 0

함정 구성의 사전 확률

$$P(P_{1,1}, \dots, P_{4,4}) = \prod_{i,j=1,2}^{4,4} P(P_{i,j})$$

15개 이하의 함정이
있는 구성의 경우
 $0.2^n \times 0.8^{15-n}$

증거(Evidence)

1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2 B OK	2,2	3,2	4,2
1,1 OK	2,1 B OK	3,1	4,1

$$b = \neg b_{1,1} \wedge b_{1,2} \wedge b_{2,1}$$

$$known = \neg p_{1,1} \wedge \neg p_{1,2} \wedge \neg p_{2,1}$$

Query $P(P_{1,3} \mid known, b)$?

// 현재까지 관측된 내용을 바탕으로 [1,3]에 함정이 있을 확률은?


◆ **Unknown**: 알려진 세 개의 사각형과 쿼리 사각형 [1, 3]을 제외한 12개의 $P_{i,j}$ 집합

$$P(P_{1,3} \mid known, b) = \alpha \sum_{unknown} P(P_{1,3}, known, b, unknown)$$

$$\in \{(p_{1,4}, p_{2,2}, \dots, p_{4,4}), \dots, (\neg p_{1,4}, \neg p_{2,2}, \dots, \neg p_{4,4})\}$$

♠ $2^{12}=4096$ 개의 항에 대한 합 (전체 결합 확률을 알고 있다는 전제하에)

방의 개수에 지수적으로 비례하여 증가!



고려하지 않아도 되는 방들?


1,4	2,4	3,4	4,4
1,3	2,3	3,3	4,3
1,2 B OK	2,2	3,2	4,2
1,1 OK	2,1 B OK	3,1	4,1

Frontier. 방문한 방에 인접한 방들에 대한 함정 변수

[2,2] and [3,1]

Other. 그 외의 미지의 방들에 대한 함정 변수
10개의 다른 방들이 존재

$$Unknown = Frontier \cup Other$$



Insight: KNOWN, QUERY, FRONTIER가 알려진 상태에서 바람이 관찰된 경우, 이는 Other에 대해 조건부 독립인 사상이 됨

합정이 있을 확률

$$P(P_{1,3} \mid \text{known}, b) = \alpha' P(P_{1,3}) \sum_{\text{frontier}} \underbrace{P(b \mid P_{1,3}, \text{known}, \text{frontier})}_{= 1 \text{ or } 0} P(\text{frontier})$$

♣ 분포 $P(b \mid P_{1,3}, \text{known}, \text{frontier})$ 에서의 확률은 b 가 $P_{1,3}$ 의 값 및 "frontier"에 있는 변수들과 연관되는 경우에는 1이고, 그렇지 않으면 0

♣ $P_{1,3}$ 에 대한 모든 값에 대해, **known 상태에 부합하는** frontier 변수에 대한 **논리 모델들의 합산**

Frontier = $\{P_{2,2}, P_{3,1}\}$ 에
부합하는 5개의 모델:

1,3		
1,2 B	2,2	
OK		
1,1	2,1 B	3,1
OK	OK	

$$0.2 \times 0.2 = 0.04$$

1,3		
1,2 B	2,2	
OK		
1,1	2,1 B	3,1
OK	OK	

$$0.2 \times 0.8 = 0.16$$

1,3		
1,2 B	2,2	
OK		
1,1	2,1 B	3,1
OK	OK	

$$0.8 \times 0.2 = 0.16$$

1,3		
1,2 B	2,2	
OK		
1,1	2,1 B	3,1
OK	OK	

$$0.2 \times 0.2 = 0.04$$

1,3		
1,2 B	2,2	
OK		
1,1	2,1 B	3,1
OK	OK	

$$0.2 \times 0.8 = 0.16$$

$$b = \neg b_{1,1} \wedge b_{1,2} \wedge b_{2,1}$$

$$\text{known} = \neg p_{1,1} \wedge \neg p_{1,2} \wedge \neg p_{2,1}$$

$$P(P_{1,3} \mid \text{known}, b) = \alpha' \langle 0.2(0.04 + 0.16 + 0.16), 0.8(0.04 + 0.16) \rangle \\ \approx \langle 0.31, 0.69 \rangle$$

[1,3] 은 31% 의 확률로 합정임